

排队的艺术

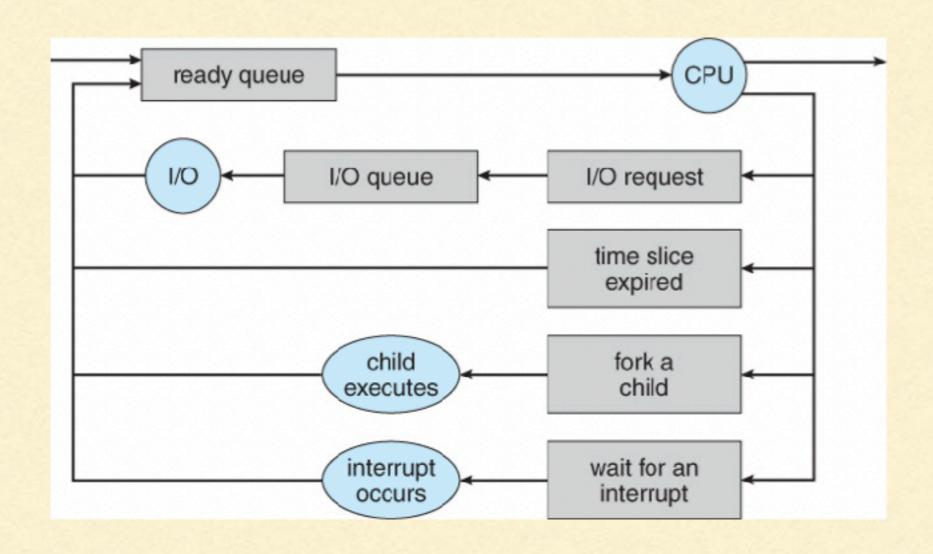
# 内容

- 到处都在排队
- 如何优雅排队
- 事 排队论的应用

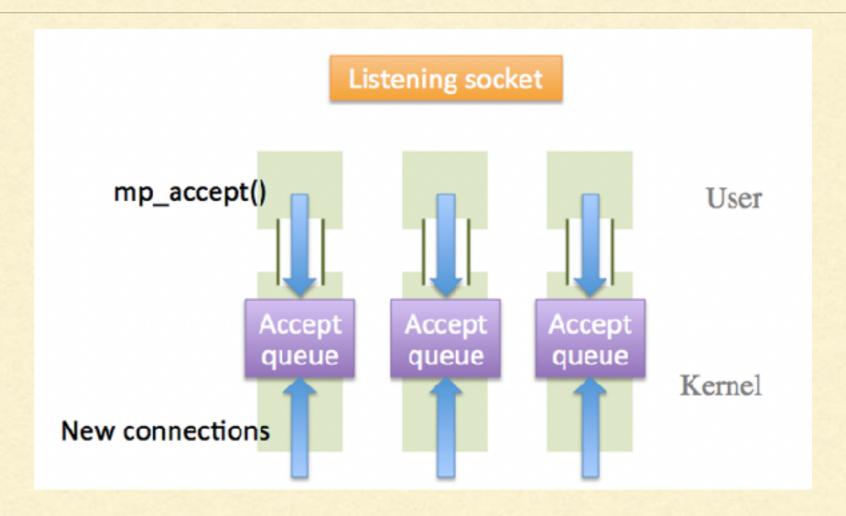








磁盘的util > 80%, 有性能问题吗?



#### TCP建立立连接涉及的两个队列:

- SYN\_RECV状态的队列, net.ipv4.tcp\_max\_syn\_backlog
- ESTABLISHED状态的队列, min(net.core.somaxconn, backlog)

# 当我们讨论排队时,我们都关心什么

- 什么时候过去,排队的时间会比较短?
- 不排队的话,需要多少时间?
- - 我前面一共还有几人?
- - 排到我需要多少时间?
- 等我服务结束,又需要多少时间?
- - 队伍长队达到什么程度, 我就会放弃排队?
- -有多少个服务窗口?

# 当我们讨论排队时, 我们都关心什么

- 想新开一家KFC,人流量是否够?需要多少收银人员?需要 多少位置?
- 银行营业厅内,先统一领号,再各窗口叫号,科学吗?
- 应该部署几台服务器? 异步线程池应该开多大? 等待队列该怎么选? 容量多少?
- 如何解读命令iostat显示的磁盘性能指标?

## 优雅排队的艺术—QUEUING THEORY

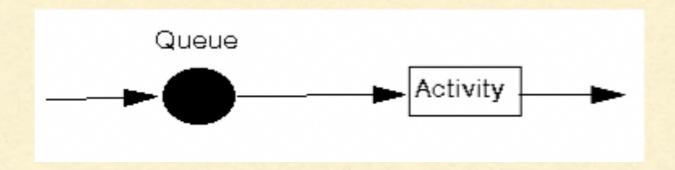
- 无论是现实中的排队,电话通讯领域的排队,还是计算机领域的排队,都能够抽象化为一个经典的理论——排队论。
- 起源于20世纪初的电话通话。1909—1920年丹麦数学家、电气工程师 A.K.Erlang用概率论方法研究电话通话问题,从而开创了这门应用数学学科。

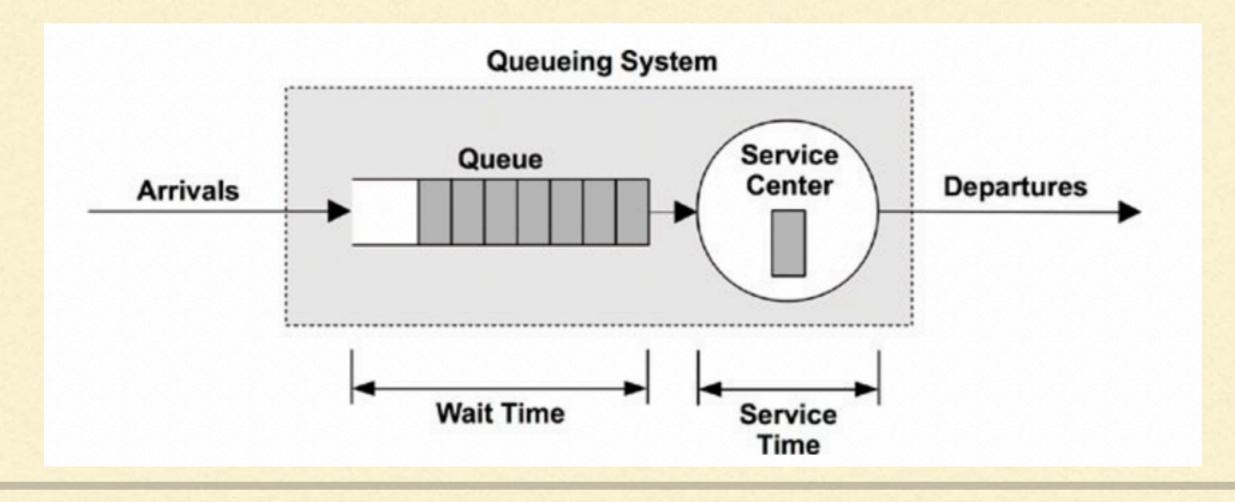
# 优雅排队的艺术一解决什么问题?

- 对用户来说:响应时间 (满意度)
- 对服务提供者来说: 利用率 (成本)

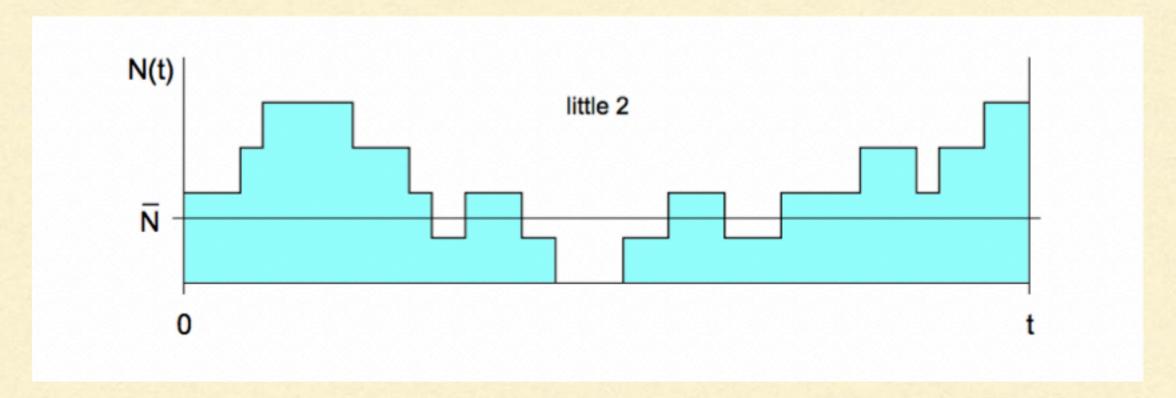
在保障用户满意度的前提下,最大限度的控制成本, 充分挖掘系统的潜力。——性能!

# 优雅排队的艺术一抽象模型





## 优雅排队的艺术—LITTLE'S LAW



- N(t): t时刻Queuing System内存在的请求数
- N: Queuing System内在t时段的平均请求数
- T: 请求在Queuing System内的平均耗时
- λ: 单位时间进入Queuing System的请求数

# 优雅排队的艺术—LITTLE'S LAW

Little's Theorem:  $N=\lambda *T$ 

存量数量 = 到达速率 \* 平均响应时间

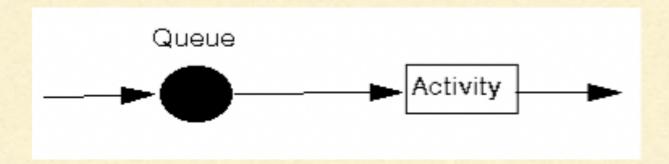
- 平均响应时间越长, 队列长度也越长
- 单位时间到达的请求越多,队列长度越长

# 优雅排队的艺术—LITTLE'S LAW

## 例子:

一个小酒馆,客户平均访问频率为40人/小时;客户在小酒馆的平均消费时间是15分钟。那么,小酒馆的平均客户数量是多少?

解答: 40人/小时\*0.25小时/人=10

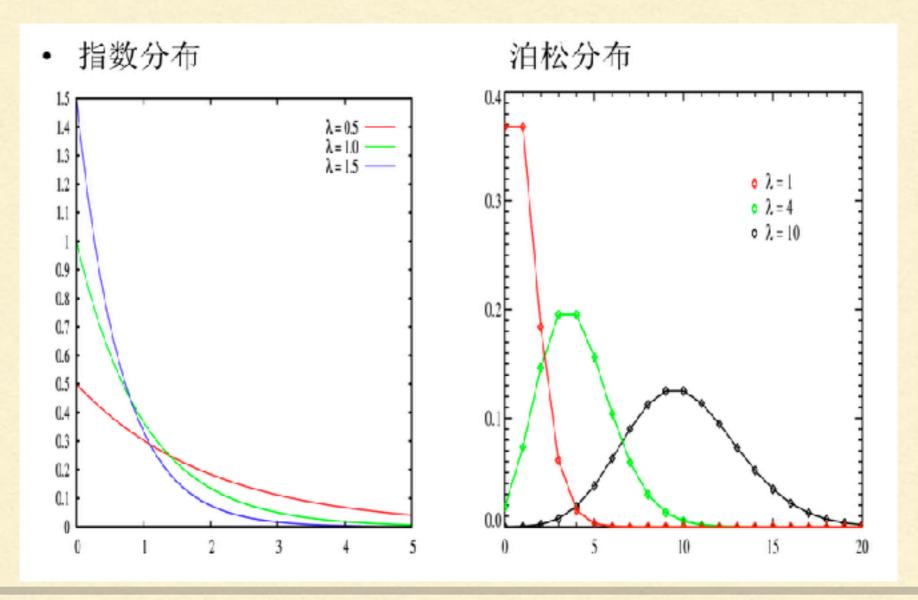


# 为什么会形成队列?

## 随机事件!

- · 导致进队列的Arrival有什么规律?
- · 导致离开系统的Service有什么规律?

指数分布: 耗时与间隔,如婴儿出生的时间间隔、来电的时间间隔 泊松分布: 事件发生,如每小时出生3个婴儿、每10分钟接到1个电话



# Arrival和Service均有可能遵循:

- M(Exponential/Markov):
  - 事件之间的时间间隔呈指数分布
  - 单位时间的事件次数呈泊松分布
- D(Deterministic): 频率或间隔固定
- G(General):无规律

两个关键行为Arrival和Service的规律

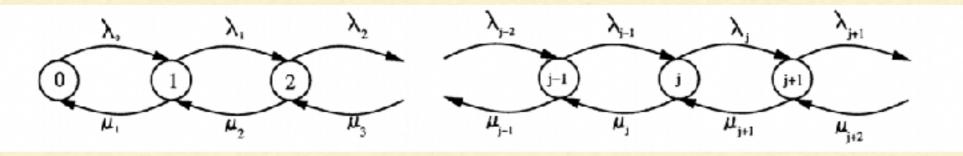


系统的整体状态有什么规律?



#### 用系统中存量请求的数量表示系统的状态P,

每一个状态, 只跟他前后两个状态有关。



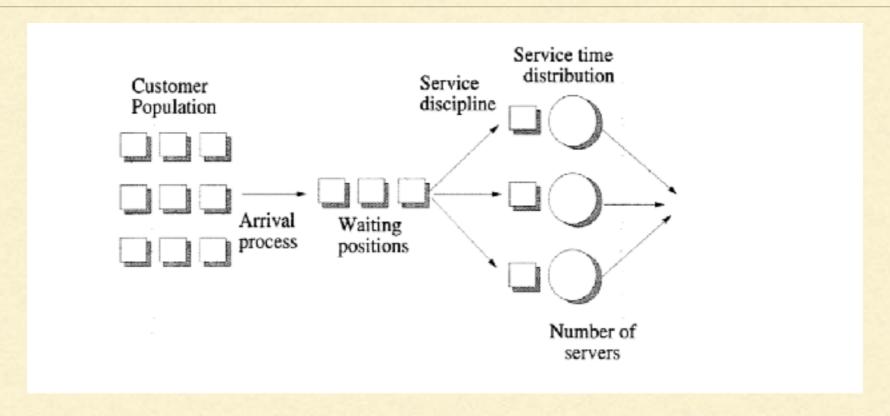
Markov链处于稳态时, 节点的输入等于输出:

$$P_0 \lambda = P_1 \mu$$

$$P_1(\lambda + \mu) = P_0 \lambda + P_2 \mu$$

$$P_j(\lambda + \mu) = P_{j-1} \lambda + P_{j+1} \mu$$

#### 优雅排队的艺术—KENDALL NOTATION



Queuing System可描述为: A/S/c, 称为Kendall Notation

A: 请求到达过程,

S: 服务过程,

c: 表示服务承接者数量.

# 优雅排队的艺术—M/M/1模型

示例: M/M/1, 最典型、最常见的模型

- 请求到达的间隔指数分布/单位时间到达数量泊松分布 (M)
- -服务时间指数分布 (M)
- —↑Server (1)

Kendall Notation的六元形式: A/S/c/K/N/D, 额外包括:

- K: 队列最大长度, 默认为无限
- N: 请求总数量,默认为无限
- D: 服务的调度策略, 默认为先到先服务

# 优雅排队的艺术—M/M/1模型

· Server的利用率是多少?

$$U = \rho = \frac{\lambda}{\mu} (\lambda < \mu)$$

平均服务时间是多少?

$$S = \frac{1}{\mu}$$

服务队列长度是多少?

$$L_s = \lambda \cdot \frac{1}{u} = \frac{\lambda}{u}$$

Server空闲概率是多少?

$$P_c = 1 - U = 1 - \frac{\lambda}{\mu}$$

• 一个请求,需要等待的概率是多少?

$$P_{t} = 1 - \bar{F}_{0} = \frac{\hat{\lambda}}{u}$$

#### 已知:

- 单位时间到达的请求: λ
- 单位时间处理的请求: µ

• 总队列长度是多少?

$$L = \sum_{i=1}^{\infty} i P_i = \sum_{i=1}^{\infty} i (1-\rho) \rho^i = \frac{\rho}{1-\rho} = \frac{\lambda}{\mu-\lambda}$$

等待队列长度是多少?

$$L_v = \sum_{i=1}^{\infty} (i-1)P_i = \frac{\rho^2}{1-\rho}$$

平均响应时间是多少?

$$R = \frac{L}{\lambda} = \frac{1}{\mu} \frac{1}{1 - \rho} = \frac{1}{\mu - \lambda}$$

平均等待时间是多少?

$$W = \frac{L_v}{\lambda} = \frac{1}{\mu} \frac{\rho}{1 - \rho} = R - S$$

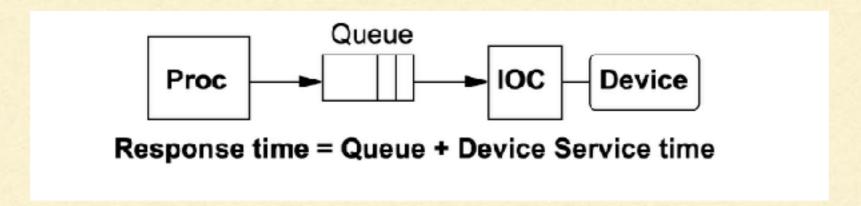
示例: M/M/1, 最典型、最基础的模型

1.

// Creates an Executor that uses a single worker thread operating off an unbounded queue

final ExecutorService exService =
Executors.newSingleThreadExecutor();

#### 2. 磁盘10



# 计算器:

- Queueing Theory Calculator
- Queuing Calculator

KFC窗口每小时有100人光顾,平均每人需要30秒完成购买并离开,问:

- 顾客需要在窗口前呆多久(排队+购买)?
- 排队需要多久?
- 窗口前会有多少顾客(排队+购买中)?

# 利用率与响应时间之间的关系 $S = \frac{1}{\mu} \frac{1}{1-\mu} (\mathbb{R}^{n}, \frac{1}{\mu}) \times \mathbb{R}^{n}$ $S = \frac{1}{\mu} \frac{1}{\mu} \frac{1}{\mu} \times \mathbb{R}^{n}$ $S = \frac{1}{\mu} \times \mathbb{R}^{n}$

$$R = 1 / (\mu - \lambda)$$

I/O Requests/sec	Server Utilization	Mean response time (ms)
64	50%	15.6
72	56%	17.8
80	62%	20.7
88	69%	24.9
96	75%	31.1
104	81%	41.3
112	87%	61.7
120	94%	121.9
124	97%	237.8

# M/M/1/k模型

- 请求到达的间隔指数分布/单位时间到达数量泊松分布 (M)
- -服务时间指数分布 (M)
- —↑Server (1)
- 无限等待队列长度 等待队列长度为k, 超过则拒绝
- 无限请求数量 (默认)
- 先到先服务的调度策略 (默认)

#### 现实意义

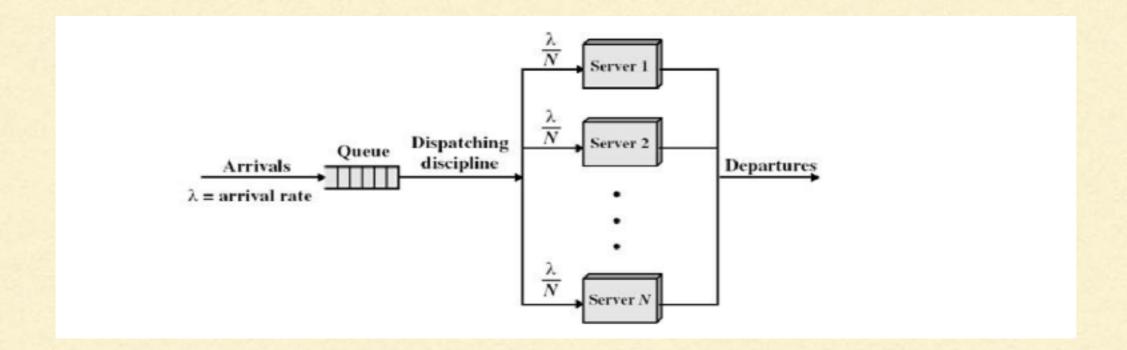
- 大部分现实中的系统,都是有最大等待队列限制的;
- 哪怕是没有限制,用户发现队列过长时,也会主动放弃;

#### 关键问题

- 请求到达时,发现队列已满,而被丢弃的概率是多少?
- 要求丢弃概念小于一定值时, 队列容量该如何设置?

对于长为n的队列,丢弃的概率P为: $\rho^n * (1-\rho) / (1-\rho^n (n+1))$ 

# m个处理能力相同的server 一个排队队列(无限)



使用率 $\rho = \lambda/m\mu$  响应时间 $R = 1/\mu * 1/(1-\rho^m)$ 

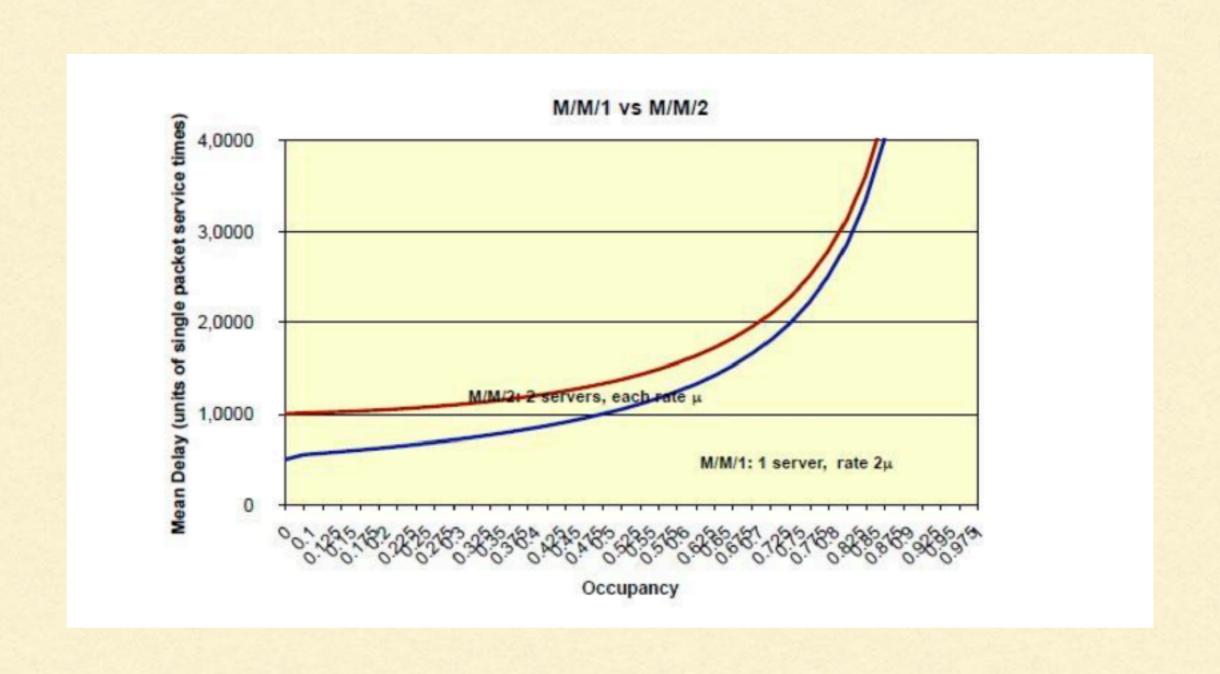
# 现实意义:

• 从安全和性能出发,一般会有多个服务节点

# 关键问题:

• 要多少个服务节点,才能不至于因等待太久而放弃?

# 排队论的应用—M/M/m vs M/M/1



#### 场景:

Kafka可视为队列,某topic的消费者每秒种只能处理1个消息, 无法满足业务需求。

#### 问题:

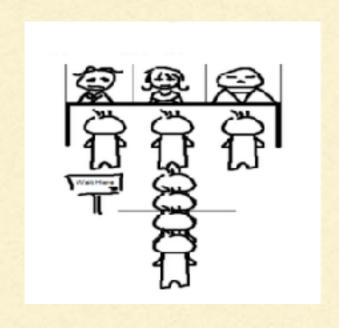
以下三种应对方案,哪个更"经济"?

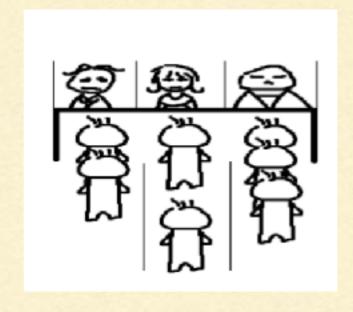
- 优化处理逻辑,使速度提升一倍
- 添加一个相同的消费者(添加了partition)
- 拆分成两个topic,带两相同消费者

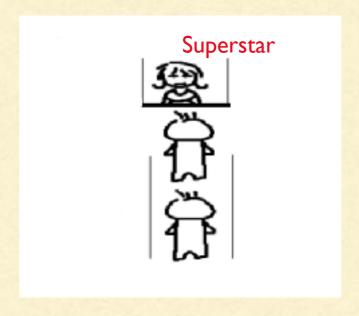
● M/M/m: m个Server, 1个队列, 平均处理速度μ, 总速度mμ

● m M/M/1: m个Server, m个队列, 平均处理速度µ, 总速度mµ

M/M/1: 1个Server, 1个队列, 平均处理速度mμ, 总速度mμ







优衣库

**KFC** 

?

- M/M/m: m个Server, 1个队列, 平均处理速度 $\mu$ , 总速度m $\mu$  R = 1/ $\mu$  \* 1 /(1- $\rho$ ^m)
- m M/M/1: m个Server, m个队列, 平均处理速度μ, 总速度mμ  $R = 1/\mu * 1/(1-\rho)$
- M/M/1: 1个Server, 1个队列, 平均处理速度mμ, 总速度mμ
   R = 1/mμ \* 1/ (1-ρ)

## 结论:

 $M/M/1(m\mu) > M/M/m > m M/M/1$ 

# 启发:

- 一个效率10的程序员 > 10个效率1的程序员
- 软硬件的性能, 先追求单机极致, 再是多机

# 参考

- <a href="https://cs.gmu.edu/~menasce/cs700/files/PerformanceModelingl.pdf">https://cs.gmu.edu/~menasce/cs700/files/PerformanceModelingl.pdf</a>
- http://bnrg.eecs.berkeley.edu/~randy/Courses/CS252.S96/Lecture21.pdf
- https://www.win.tue.nl/~iadan/queueing.pdf
- <a href="https://goldenratiphi.wordpress.com/2013/05/06/comparison-between-single-and-multiple-queues/">https://goldenratiphi.wordpress.com/2013/05/06/comparison-between-single-and-multiple-queues/</a>
- https://www.csus.edu/indiv/b/blakeh/mgmt/documents/opm101supplc.pdf
- http://williams.comp.ncat.edu/comp755/Q.pdf
- http://web.engr.illinois.edu/~dmnicol/ece54 l/slides/queueing.pdf
- http://www.supositorio.com/rcalc/rcalclite.htm
- http://people.brunel.ac.uk/~mastjjb/jeb/or/queue.html
- http://www.netlab.tkk.fi/opetus/s383 I 43/kalvot/english.shtm
- http://ocw.nctu.edu.tw/upload/classbfs121001554684839.pdf
- http://www.ruanyifeng.com/blog/2015/06/poisson-distribution.html
- http://web2.uwindsor.ca/math/hlynka/qsoft.html
- https://www.stat.auckland.ac.nz/~stats255/qsim/qsim.html
- https://pan.baidu.com/share/link?uk=4265849107&shareid=4118923932